

In [1]:

```
import sklearn
import numpy as np
import pandas as pd
import seaborn as sns
```

In [2]:

```
iris_df = pd.read_csv('iris.data', header=None, names=['sepal length', 'sepal width', 'petal length', 'petal width', 'class'])
glass_df = pd.read_csv('glass.data', index_col=0, header=None, names=['Id', 'RI', 'Na', 'Mg', 'Al', 'Si', 'K', 'Ca', 'Ba', 'Fe', 'Type of glass'])
wine_df = pd.read_csv('wine.data', header=None, names=['class', 'Alcohol', 'Malic acid', 'Ash', 'Alcalinity of ash', 'Magnesium', 'Total phenols', 'Flavanoids', 'Nonflavanoid phenols', 'Proanthocyanins', 'Color intensity', 'Hue', 'OD280/OD315 of diluted wines', 'Proline'])
```

Iris

In [3]:

```
print(iris_df)
```

	sepal length	sepal width	petal length	petal width	class
0	5.1	3.5	1.4	0.2	Iris-setosa
1	4.9	3.0	1.4	0.2	Iris-setosa
2	4.7	3.2	1.3	0.2	Iris-setosa
3	4.6	3.1	1.5	0.2	Iris-setosa
4	5.0	3.6	1.4	0.2	Iris-setosa
..
145	6.7	3.0	5.2	2.3	Iris-virginica
146	6.3	2.5	5.0	1.9	Iris-virginica
147	6.5	3.0	5.2	2.0	Iris-virginica
148	6.2	3.4	5.4	2.3	Iris-virginica
149	5.9	3.0	5.1	1.8	Iris-virginica

[150 rows x 5 columns]

3 klasy oznaczające gatunki irysów, po 50 instancji każdej

pierwsze 2 kolumny `sepal length` i `sepal width` **oznaczają długość i szerokość działki kielicha w cm**

`petal length` i `petal width` **oznaczają długość i szerokość płatków w cm**

Iris-versicolor i Iris-virginica są do siebie mniej więcej podobne patrząc na dowolne atrybuty, podczas gdy Iris-setosa wyróżnia się kiedy patrzymy na dowolny wymiar płatka lub oba wymiary działki kielicha

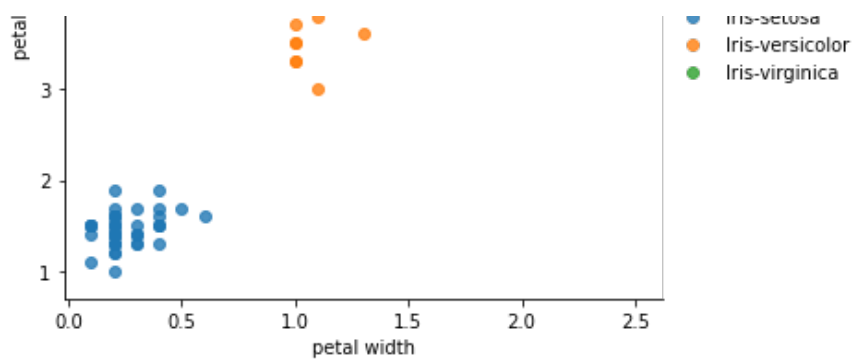
In [4]:

```
sns.lmplot(x='petal width', y='petal length', hue='class', data=iris_df, fit_reg=False)
```

Out[4]:

<seaborn.axisgrid.FacetGrid at 0x14981d82580>



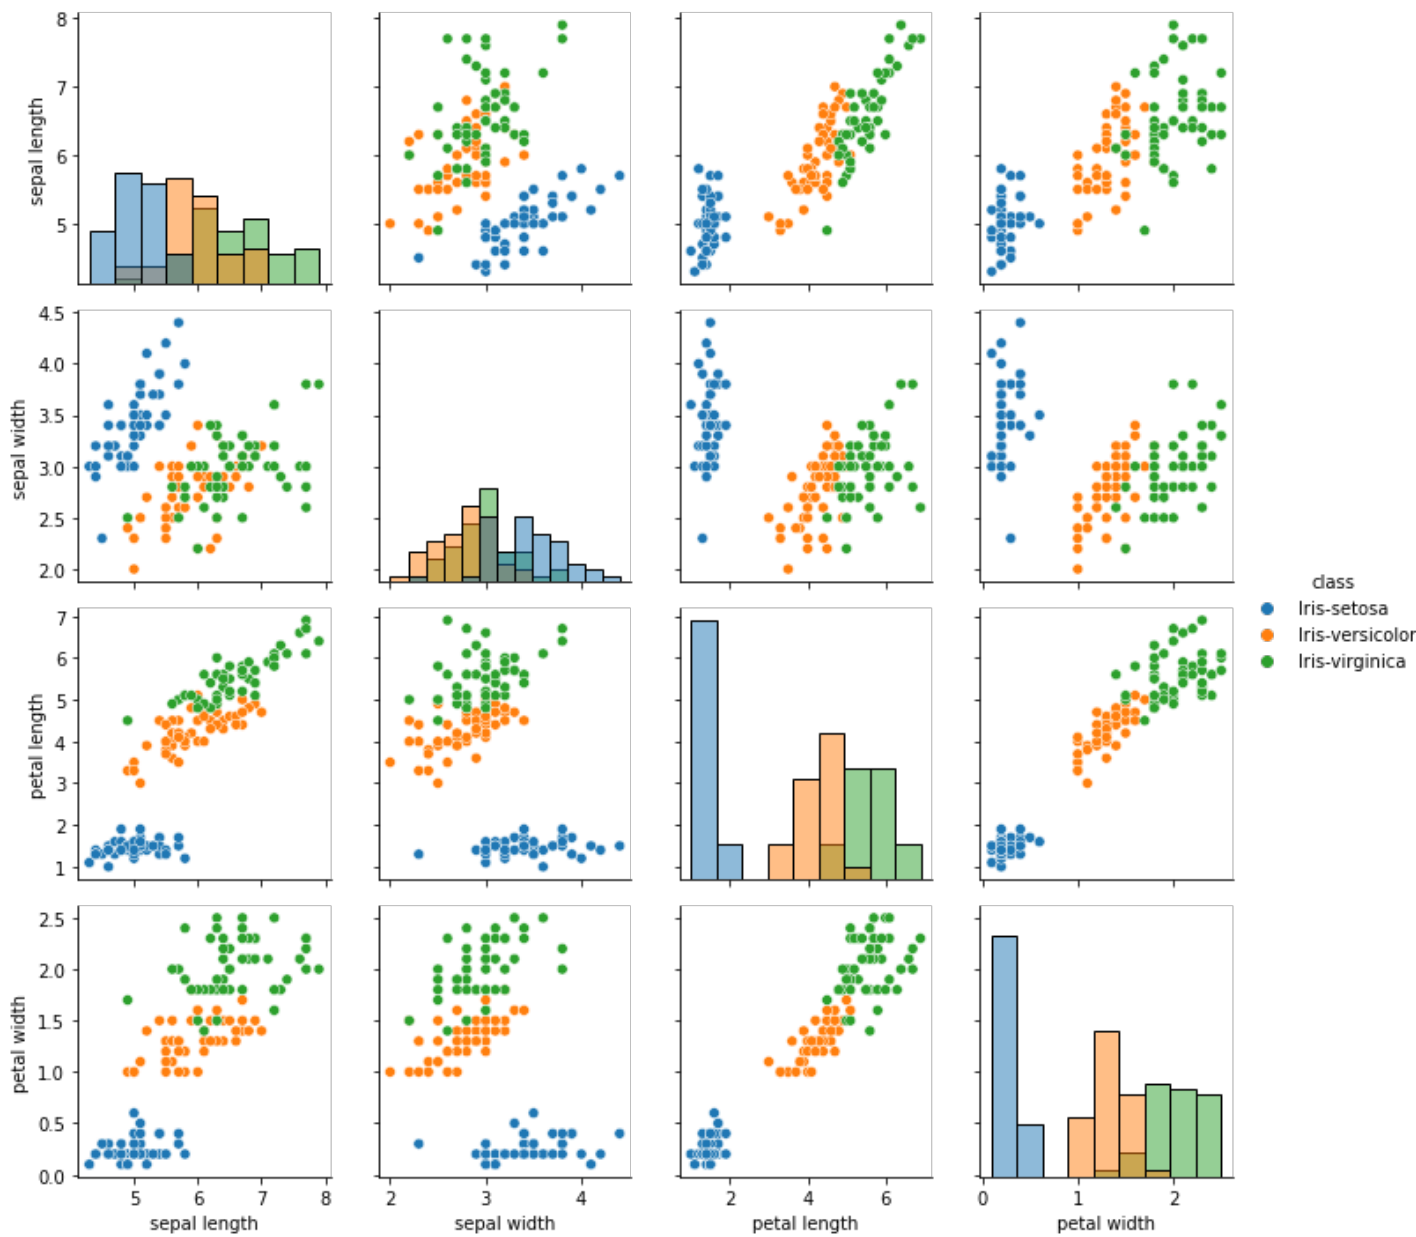


In [5]:

```
iris_grid = sns.PairGrid(iris_df, hue='class')
iris_grid.map_diag(sns.histplot)
iris_grid.map_offdiag(sns.scatterplot)
iris_grid.add_legend()
```

Out[5]:

<seaborn.axisgrid.PairGrid at 0x14984ef8670>



Glass

In [6]:

```
print(glass_df)
```

	RI	Na	Mg	Al	Si	K	Ca	Ba	Fe	Type of glass
Id										
1	1.52101	13.64	4.49	1.10	71.78	0.06	8.75	0.00	0.0	1
2	1.51761	13.89	3.60	1.36	72.73	0.48	7.83	0.00	0.0	1
3	1.51618	13.53	3.55	1.54	72.99	0.39	7.78	0.00	0.0	1
4	1.51766	13.21	3.69	1.29	72.61	0.57	8.22	0.00	0.0	1
5	1.51742	13.27	3.62	1.24	73.08	0.55	8.07	0.00	0.0	1
..
210	1.51623	14.14	0.00	2.88	72.61	0.08	9.18	1.06	0.0	7
211	1.51685	14.92	0.00	1.99	73.06	0.00	8.40	1.59	0.0	7
212	1.52065	14.36	0.00	2.02	73.42	0.00	8.44	1.64	0.0	7
213	1.51651	14.38	0.00	1.94	73.61	0.00	8.48	1.57	0.0	7
214	1.51711	14.23	0.00	2.08	73.36	0.00	8.62	1.67	0.0	7

[214 rows x 10 columns]

kolumna `Id` zawiera indeksy próbek szkła

kolumna `RI` zawiera współczynniki załamania szkła

ostatnia kolumna `Type of glass` zawiera indeksy 1-7 różnych typów szkła

liczba instancji każdej klasy:

1. 70
2. 76
3. 17
4. 0
5. 13
6. 9
7. 29

pozostałe kolumny zawierają procentową zawartość odpowiadających pierwiastków


patrząc na wykresy jedynym jakimkolwiek wyróżniającym się typem szkła jest szkło reflektorów (7), głównie z powodu wyższej zawartości baru

In [7]:

```
sns.lmplot(x='RI', y='Ba', hue='Type of glass', data=glass_df, fit_reg=False)
```

Out[7]:

<seaborn.axisgrid.FacetGrid at 0x14985187070>



Tn [8]:

	class	Alcohol	Malic acid	Ash	Alcalinity of ash	Magnesium
0	1	14.23	1.71	2.43	15.6	127
1	1	13.20	1.78	2.14	11.2	100
2	1	13.16	2.36	2.67	18.6	101
3	1	14.37	1.95	2.50	16.8	113
4	1	13.24	2.59	2.87	21.0	118
...
173	3	13.71	5.65	2.45	20.5	95
174	3	13.40	3.91	2.48	23.0	102
175	3	13.27	4.28	2.26	20.0	120
176	3	13.17	2.50	2.27	22.2	122

176	3	13.17	2.59	2.37	20.0	120
177	3	14.13	4.10	2.74	24.5	96
	Total phenols	Flavanoids	Nonflavanoid phenols	Proanthocyanins		\
0	2.80	3.06	0.28	2.29		
1	2.65	2.76	0.26	1.28		
2	2.80	3.24	0.30	2.81		
3	3.85	3.49	0.24	2.18		
4	2.80	2.69	0.39	1.82		
..		
173	1.68	0.61	0.52	1.06		
174	1.80	0.75	0.43	1.41		
175	1.59	0.69	0.43	1.35		
176	1.65	0.68	0.53	1.46		
177	2.05	0.76	0.56	1.35		

	Color intensity	Hue	OD280/OD315 of diluted wines	Proline
0	5.64	1.04	3.92	1065
1	4.38	1.05	3.40	1050
2	5.68	1.03	3.17	1185
3	7.80	0.86	3.45	1480
4	4.32	1.04	2.93	735
..
173	7.70	0.64	1.74	740
174	7.30	0.70	1.56	750
175	10.20	0.59	1.56	835
176	9.30	0.60	1.62	840
177	9.20	0.61	1.60	560

[178 rows x 14 columns]

kolumna `class` zawiera indeksy 1-3 oznaczające różne odmiany wina z liczbami instancji

1. 59
2. 71
3. 48

pozostałe kolumny zawierają informacje o właściwościach chemicznych wina


wszystkie 3 klasy są częściowo rozróżnialne patrząc na różne atrybuty, np. odmiana 1. ma większą zawartość proliny, odmiana 2. ma mało intensywny kolor i próbki odmiany 3. mają podobny do siebie odcień

In [10]:

```
sns.lmplot(x='Color intensity', y='Hue', hue='class', data=wine_df, fit_reg=False)
```

Out[10]:

<seaborn.axisgrid.FacetGrid at 0x14985b03190>



In [11]:

```
wine_grid = sns.PairGrid(wine_df, hue='class')  
wine_grid.map_diag(sns.histplot)  
wine_grid.map_offdiag(sns.scatterplot)  
wine_grid.add_legend()
```

Out[11]:

<seaborn.axisgrid.PairGrid at 0x14989ea5880>



PCA

In [12]:

```
from sklearn.preprocessing import StandardScaler  
from sklearn.decomposition import PCA
```

Iris

In [13]:



```

features = ['sepal length', 'sepal width', 'petal length', 'petal width']
x = iris_df.loc[:, features].values
y = iris_df.loc[:, ['class']].values
x = StandardScaler().fit_transform(x)
pca = PCA(n_components=2)
principalComponents = pca.fit_transform(x)
principalDf = pd.DataFrame(data = principalComponents, columns = ['principal component 1', 'principal component 2'])
finalDf = pd.concat([principalDf, iris_df[['class']]], axis = 1)
sns.lmplot(x='principal component 1', y='principal component 2', hue='class', data=finalDf, fit_reg=False)

```

Out[13]:

<seaborn.axisgrid.FacetGrid at 0x14992fa1190>



Glass

In [14]:


```


features = ['RI', 'Na', 'Mg', 'Al', 'Si', 'K', 'Ca', 'Ba', 'Fe']
x = glass_df.loc[:, features].values
y = glass_df.loc[:, ['Type of glass']].values
x = StandardScaler().fit_transform(x)
pca = PCA(n_components=2)
principalComponents = pca.fit_transform(x)
principalDf = pd.DataFrame(data = principalComponents, columns = ['principal component 1', 'principal component 2'])
finalDf = pd.concat([principalDf, glass_df[['Type of glass']]], axis = 1)
sns.lmplot(x='principal component 1', y='principal component 2', hue='Type of glass', data=finalDf, fit_reg=False)

```

Out[14]:

<seaborn.axisgrid.FacetGrid at 0x14992fa12e0>





Wine

In [15]:

```
features = ['Alcohol', 'Malic acid', 'Ash', 'Alcalinity of ash', 'Magnesium', 'Total phe
nols', 'Flavanoids', 'Nonflavanoid phenols', 'Proanthocyanins', 'Color intensity', 'Hue'
, 'OD280/OD315 of diluted wines', 'Proline']
x = wine_df.loc[:, features].values
y = wine_df.loc[:, ['class']].values
x = StandardScaler().fit_transform(x)
pca = PCA(n_components=2)
principalComponents = pca.fit_transform(x)
principalDf = pd.DataFrame(data = principalComponents, columns = ['principal component 1
', 'principal component 2'])
finalDf = pd.concat([principalDf, wine_df[['class']], axis = 1)
sns.lmplot(x='principal component 1', y='principal component 2', hue='class', data=finalD
f, fit_reg=False)
```

Out[15]:

<seaborn.axisgrid.FacetGrid at 0x1499301e310>

